

doi: 10.3969/j.issn.1002-0268.2023.S2.007

基于 LSTM-BPNN 神经网络的沥青路面性能预测模型研究

张盼盼^{1,2}, 权磊^{*1}, 李思李¹, 胡森², 赵银³

(1. 交通运输部公路科学研究院, 北京 100088; 2. 重庆交通大学 土木工程学院, 重庆 400074;

3. 青海省交通规划设计研究院有限公司, 青海 西宁 810002)

摘要: 为解决传统网络模型预测沥青路面长期性能变化的局限性, 同时考虑数据的基本特征和时序特征, 提出了基于 LSTM-BPNN (BP 神经网络-长短期记忆网络) 神经网络的沥青路面长期性能预测方法与流程, 并基于美国长期路面性能数据库, 进行了国际平整度指数 *IRI* 的预测及预测效果验证。结果表明: 采用预测模型对沥青路面的平整度指数 (*IRI*) 进行预测时, 发现提出的 LSTM-BPNN 模型的准确率达到 86.16%, 预测曲线与实测值的吻合度较高, 可准确反应沥青路面性能的变化过程, 说明 LSTM-BPNN 神经网络预测模型在预测沥青路面长期性能方面具有较好的适用性和准确度, 可为确定沥青路面养护维修提供参考。

关键词: 道路工程; 深度学习; LSTM-BPNN; 沥青路面; 性能预测

中图分类号: U418.6

文献标识码: A

文章编号: 1002-0268 (2023) S2-0054-07

Model for Asphalt Pavement Performance Prediction Based on LSTM-BPNN Neural Network

ZHANG Pan-pan^{1,2}, QUAN Lei^{*1}, LI Si-li¹, HU Sen², ZHAO Yin³

(1. Research Institute of Highway, Ministry of Transport, Beijing 100088, China;

2. School of Civil Engineering, Chongqing Jiaotong University, Chongqing 400074, China;

3. Qinghai Transportation Planning and Design Institute Co., Ltd., Xining, Qinghai 810002, China)

Abstract: To solve the limitations of traditional network model for predicting long-term performance variation of asphalt pavement, the method and process for predicting long-term performance of asphalt pavement based on LSTM-BPNN neural network considering the basic characteristics and time series characteristics of data were proposed. Based on the long-term pavement performance database of the United States, the prediction and prediction effect of international flatness index *IRI* were carried out. The result indicates that when the prediction model is used to predict the international roughness index (*IRI*) of asphalt pavement, the accuracy of proposed LSTM-BPNN model reaches 86.16%. It shows that the prediction curve is in good agreement with the measured value, which can accurately reflect the variation process of asphalt pavement performance. It can indicate that the LSTM-BPNN neural network prediction model has good applicability and accuracy in predicting long-term performance of asphalt pavement, which can provide the reference for determining maintenance and repair of asphalt pavement.

Key words: road engineering; deep learning; LSTM-BPNN; asphalt pavement; performance prediction

收稿日期: 2023-10-29

基金项目: 国家自然科学基金项目 (52178427, 52308454); 北京市自然科学基金项目 (8222034); 交通运输部公路科学研究所 (院) 交通强国试点项目 (QG2021-2-5-1)

作者简介: 张盼盼 (1990-), 女, 河北衡水人, 硕士. (zhangpanpan648@126.com)

* 通讯作者: 权磊 (1987-), 男, 陕西富平人, 博士, 副研究员. (charly08@163.com)

0 引言

目前, 学界人员开发不少的高速公路沥青路面的性能预测模型^[1-4], 主要以概率性、确定性等多种形式的预测模型, 针对养护维修单个衰变周期内的数据分析, 但该模型主要建立在包含少量简化后的路面特征数据集上, 它们很难在真实的大规模情境中实现准确的数据, 因为许多时间序列被简化成了时间截面特征, 从而忽略了整个系列的变化趋势, 如何准确预测沥青路面性能发展趋势已经成为高速公路的重要内容。

蒋玮等^[5]基于传统灰色模型, 建立了熵值赋权灰色马尔可夫模型对沥青路面使用性能进行预测, 为路面服役性能研究提供了思路; 李鑫等^[6]基于灰色系统建立了沥青路面平整度 GM (1, 1) 预测模型, 并对平整度的变化规律进行了预测; 杜顺成等^[7]选择马尔可夫模型与衰变模型组合模型进行改良及组合开发, 构建了马尔科夫预测模型与衰变模型的组合模型作为路面性能预测模型, 为相关公路养护部门提供了依据; Hosseini 等^[8]指出, 预测模型主要针对路面性能指标, 在路面性能指标的实际值与预测值之间会有一定误差传播。近几年, 人工神经网络技术在道路工程应用广泛, 它通过建立数据输入端和输出端的数据联系算法进行模型预测, 解决复杂的非线性问题^[9-10]。熊盛华等^[11]设计了一个深度神经网络模型, 通过使用交通和气候的各种统计特征来预测路面服役性能指标。董艳芳等^[12]运用遗传算法优化的反向传播 (GA-BP) 神经网络, 开展了热泵夏季低负荷运行预测分析, 验证了该方法在性能预测方面的可行性; 金昊鹏等^[13]为准确预测沥青路面在使用过程中龟裂破坏程度, 利用人工神经网络模型法对龟裂破坏进行了分析, 得到了较好的预测效果; 王立路等^[14]还曾以车辆荷载、路龄、养护费用作为路面使用性能预测指标, 采用 BP 神经网络模型进行了路面性能预测, 为路面大修时间的确定提供参考; 张志斌^[15]提出了一种基于深层循环神经网络的沥青路面技术状况评定指标预测模型, 使用循环神经网络替代传统全连接神经网络, 挖掘数据的时序关联性并进行沥青路面健康状况预测。

但是, 上述所提出的模型多基于小数据集上进行测试, 受样本量和数据类型的限制, 模型学习训练的针对性强, 使其在部分典型环境的路面性能预测的应用中受限。考虑到时间因素对整体预测模型的影响, 少量学者开始关注时序特征和时序关联性

开展道路性能预测, 但目前仍在探索和模型优化阶段。

基于此, 本研究结合路面长期性能数据库的数据特性, 将数据特征划分为基本特征数据和时序特征数据, 并结合对于此类数据具有较好的适用性的长期短期记忆 (LSTM) 与 BP 神经网络 (BPNN) 方法, 提出了基于 LSTM-BPNN 网络预测路面性能的算法, 优化确定了预测流程、数据来源、特征融合模型建立, 并依据美国长期路面性能 LTPP 数据库, 充分利用路面结构与施工、环境气候、交通荷载和路面性能等数据, 进行路面平整度 IRI 模型预测, 验证该算法的可行性。

1 基于 LSTM-BPNN 神经网络的 Lumina 模型原理和改进方法

1.1 LSTM-BPNN 模型原理

如图 1 描述了特征融合 LSTM-BPNN 模型的结构。它主要由两部分组成。




图 1 LSTM-BPNN 特征融合模型

Fig. 1 LSTM-BPNN feature fusion model

第一部分如图中的左侧部分的 BPNN。它接受不同路面的基本特征作为输入并学习相应的隐含影响因素, 其主要由输入层、隐藏层和输出层构成, 且隐藏层根据需要可设置多层, 通常为单层结构; 第二部分如右边部分为递归神经网络用于学习不同长度的气候时间序列特征。然后通过应用注意机制隐式融合时间序列与截面特征。LSTM 主要由遗忘门、输入门和输出门 3 部分组成。遗忘门决定上一时刻的隐藏层状态有多少可以保留到当前时刻, 它是一个 sigmoid 函数层; 输入门决定了当前时刻网络的输

入值有多少保存在隐藏层状态。模型的两部分以相互耦合的方式工作，其最终输出表示 BPNN 和 LSTM 的整体输出。

1.2 预测流程改进方法

根据构建的基于深度学习 BPNN-LSTM 神经网络大数据预测模型，提出了路面服役性能预测方法，流程图如图 2 所示。




图 2 预测方法流程

Fig. 2 Flow of prediction method

道路基础设施服役性能预测整个流程分为：确定预测目标、数据获取、数据预处理、特征提取、模型构建和模型评估、预测效果验证；本研究采用平整度 IRI 为例，采用上述流程进行国际平整度指数 IRI 的预测及预测效果验证。

1.3 数据来源

结合美国长期路面性能 LTPP 数据库考虑适用于不同场景下的路面性能指标的预测。在此基础上，将天气数据按月进行抽取，保留每月的原始数据进行特征学习，相较于其他相关工作仅使用几个简单的统计数据（例如平均值、方差），模型充分考虑了极端天气的影响，抗干扰性更强，此外还引入了路面结构特征、地理位置特征、气候分区特征、公路改善特征、交通量特征，使得数据集的特征更加丰富，充分考虑了各种因素对公路性能指标的影响。从路面长期性能数据库中导出 15 a 建模所需的数据，

大致分为路面结构与施工、环境气候、交通荷载和路面性能 4 大类，详细指标见表 1。

表 1 缩写列表

Tab. 1 List of abbreviations

道路结构（PSC）			
Age	路面服役年限	ELE	海拔
LAT	纬度	PM	道路材料
LONGI	经度	PC	道路结构
气候（CLT）			
AWD	年湿润天数	FI	年冷冻指数
AS	年降雪量	FT	年冻融天数
CR	道路所处的气候区域	AAT	年均温
AMINT	年最低温	TAP	总年降水量
AAMAXT	年日最高温均温	AMAXT	年最高温
AAMINT	年日最低温均温	AIPD	年密集降水天数
ADT32	年 32 度以上天数	ADT0	年 0 度以下天数
交通（TRF）		路用性能（Per）	
AADTT	年日均卡车交通量	IRI	国际平整度指标
AADKESAL	年等效轴载量	IRI0	初始国际平整度指标值

供建模使用的特征因素分为路面本身具有的和随时间增长而变化两类。由于长短期记忆神经网络（LSTM）在预测具有时间序列特征时远优于其他神经网络，所以把上述因素特征按照是否具有强时序性分为基本特征（表 2）和时序特征（表 3）。基本特征主要是试验路固有的不随时间明显变化的特征，包括路面服役年限和位置信息等。

表 2 基本特征统计

Tab. 2 Basic characteristic statistics

特征	范围	均值
IRI/(m·km ⁻¹)	0.346~4.473	1.478
IRI0/(m·km ⁻¹)	0.333~4.447	1.404
ELE/m	−11~2 331	486.428
LAT (abs)	18.33~62.41	38.905
LONGI (abs)	52.87~156.67	96.487
AGE/d	307~29 331	7 163.227
AADTT/(辆·日)	7~9 353	846.295
AADKESAL/kN	1~5 214	404.768

1.4 特征融合模型建立

(1) 基本特征输入：BPNN

为了模拟路面的基本特征，采用反向神经网络，因其在非线性拟合能力方面具有优异的性能。通过这种方式，模型将具有更好的捕获路面本身重要特征的能力。考虑 $l-1$ 层的第 j 个神经元的状态为 β_{jl-1} ，定义以下等式：

表 3 时序特征统计

Tab. 3 Time series characteristic statistics

特征	范围	均值
AAT/(°)	-10.9~26.6	12.402
FI/[(°) · d ⁻¹]	0.0~2 370.0	326.420
FT/d	0~209	78.709
AAMAXT/(°)	-6.4~32.6	18.875
AAMINT/(°)	-15.4~21.7	5.869
AMAXT/(°)	6.8~51.6	36.522
AMINT/(°)	-43.8~18.4	-17.537
ADT32/d	0~197	40.785
ADT0/d	0~254	103.898
TAP/mm	10.5~2 800.8	840.139
AS/次	0.0~4 411.0	672.645
AIPD/d	0~73	19.167
AWD/d	6~267	127.402

$$\beta_j^l = \text{relu}(\sum_k \mathbf{w}_{jk}^l \beta_k^{l-1} + \mathbf{b}_j), \quad (1)$$

式中, $\mathbf{w}_{jk}^l$ 为权重矩阵; $\mathbf{b}_j$ 为偏置向量。在模型中, 将 BPNN 结构的层数设置为 3, 即 S_1 , S_2 , S_3 , S_1 为基本特征的输入层; S_2 为隐藏层; S_3 为与 LSTM 部分输出连接的矩阵顶层。

(2) 时序特征输入: LSTM 长期短期记忆 (LSTM) 已成功应用于模拟时间序列特征。采用 LSTM 对气候时间序列特征进行编码, 并更好地捕捉气候变化对路面性能的影响。LSTM 部分主要由 3 个部分组成: 遗忘门, 输入门和输出门。当在 t 时刻, 输入为 x_t , 前一个隐藏层状态为 x_{t-1} , 遗忘门状态为 f_t , 则遗忘门、输入门和输出门三者的数学表达式依次如式 (2)、(3)、(4) 所示。

$$f_t = \sigma(\mathbf{W}_f[h_{t-1}, x_t] + b_f), \quad (2)$$

$$i_t = \sigma(\mathbf{W}_i[h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tan h(\mathbf{W}_c[h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t, \quad (3)$$

$$o_t = \sigma(\mathbf{W}_o[h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \cdot \tan h(C_t), \quad (4)$$

式中, $\mathbf{W}_f$, $\mathbf{W}_i$, $\mathbf{W}_c$, $\mathbf{W}_o$ 为权重向量; b_f , b_i , b_c , b_o 为偏置项。

(3) 掩蔽层

考虑到有效的时间序列特征的长度是可变的, 则在输入 LSTM 部分之前添加掩蔽层。掩蔽层将自动过滤无效特征 (例如幻数-100) 并处理具有不同长度的特征。

(4) 基于注意力的特征融合

对于 IRI 预测, 显然不同的气候变化会影响路面

的性能。在模型中, 希望有能力纳入更多信息。具体而言, 希望模拟路面的时间截面特征 (例如, 路面结构和交通相关特征) 以及气候的不同变化如何相互影响。这里应用注意机制, 因为它能够捕获更多潜在的关系。通过在 LSTM-BPNN 模型中使用注意方法, 基本特征以逐年的方式影响气候特征的权重, 并且权重 a 将通过学习过程自动加重或减少。在介绍新的注意机制之前, 首先将 S_2 和 S_3 分别定义为 BPNN 的中间层和顶层输出, 并假设网络的每一层都与非线性激活函数相关联 (例如整流线性单元)。然后, 提出了一种新方法来计算每个年度气候在 t 时的整体影响为 a_{ti} , 并考虑了路面特征:

$$\begin{bmatrix} a_1 \\ \cdots \\ a_n \end{bmatrix} = f[\mathbf{W}_a \cdot \tan h(\mathbf{W}_h h_t + \mathbf{W}_s S_2 + \mathbf{b}_a)], \quad (5)$$

式中, $\mathbf{W}_a$, $\mathbf{W}_h$, $\mathbf{W}_s$ 为权重矩阵; $\mathbf{b}_a$ 为偏置向量。另外, 函数 f 是注意力机制的输出激活函数, 可以将 f 设置为 sigmoid 或 softmax。有了这样的注意力机制, 最终输出是:

$$H = \begin{bmatrix} a_1 \\ \cdots \\ a_n \end{bmatrix} \cdot [h_1 \quad \cdots \quad h_n]. \quad (6)$$

(5) IRI 回归预测在将两个组件的输出分别设置为 S_3 和 H_t 之后, 模型通过将 S_3 和 H_t 连接在一起来计算最终回归。假设目标表示为 $\hat{y}$, 使用线性激活定义回归的输出, 如式 (7) 所示:

$$\hat{y} = \mathbf{W}_y \cdot [H; S_3] + b_y. \quad (7)$$

2 LSTM-BPNN 模型训练方法和不同模型参数取值

选择 3 种传统回归模型, 即线性回归 (LR), 梯度提升决策树 (GBDT), 极限梯度增强回归 (XGBR) 和纯 BPNN 模型进行比较。传统和神经网络模型分别用 Sklearn 和 Keras 库实现。基于树的模型, 即 GBDT 和 XGBR, 经过精心调整, 增强树的数量设置为 400。BPNN 模型有 1 个隐藏层。批量大小和训练时期设置为 128 和 512, BPNN 的输出层是线性的回归。

用 Keras 库通过 Python 来实现模型。在训练期间, 应用早期停止策略和具有指数学习率衰减的 Adam 优化器。衰减倍率的参数设置为 10。超参数使用网格搜索来查找最佳设置, 如表 4 所示, 表中列出了模型中超参数的详细设置。

使用所有基本特征和 IRI 预测的时间序列来比较 LSTM-BPNN 模型和其他模型。如表 5 所示, 为不同

表4 超参数设置

Tab.4 Hyperparameter setting

超参数	取值
BPNN 隐藏层激活函数	[relu, tanh]
注意力隐藏层激活函数	[tanh, relu]
注意力输出层激活函数	[sigmoid, softmax]
LSTM 隐状态数量	13 [8, 64]
拼接层 LSTM 神经元数量	100 [8, 512]
拼接层 BPNN 神经元数量	300 [8, 512]
输出层激活函数	linear
训练轮次	65 [8, 512]
批大小	512 [8, 1 024]
学习率衰减倍率	10 [5, 20]

模型的试验结果对比。首先，更多关键特征的参与明显提高了这些模型的预测精度。在基础模型中，0.738 的最差表现来自 LR。最好的性能来自 XGBR 模型，即 0.789。而 LSTM-BPNN 模型实现 R^2 为 0.867，比 XGBR 模型提升了 0.078（7.8%），综合远远优于 XGBR 模型，并且均方根误差 $RMSE$ 也为几类模型中表现最优的。另一方面，基于 LSTM-BPNN 网络预测模型与单独的 BPNN 预测模型相比， R^2 提升了 0.093（9.3%），均方根误差 $RMSE$ 降低

了 0.111，这也是 LSTM-BPNN 模型的重大改进。

表5 融合特征输入试验结果

Tab.5 Experimental result of fusion features input

模型	R^2	$RMSE$
LR (All)	0.738	0.350
BPNN (All)	0.774	0.353
GBDT (All)	0.781	0.320
XGBR (All)	0.789	0.316
LSTM-BPNN (Softmax)	0.855	0.258
LSTM-BPNN (Sigmoid)	0.867	0.242

LSTM-BPNN 模型虽可实现平整度的高精度预测，但其不能像基于决策树的预测模型一样实现特征重要性排序和可视化解释预测过程。另外该模型具有一定的泛化能力，只要提供高质量数据集，可进行平整度、抗滑性能、车辙深度等路用性能的预测。

3 预测结果分析

结合上述网络模型参数讨论分析，得出超参数的最优值。基于 LSTM-BPNN 模型及历年沥青路面检测数据预估路面状况平整度指数（IRI）指数为例验证的发展趋势，预测结果如图3所示。




图3 IRI 性能指标预测结果

Fig.3 Prediction result for IRI performance indicators

根据图 4 可知, 路面状况指数 *IRI* 和行驶质量指数 *RQI* 的结果等级为优的占 86.84%, 等级为良占 10.44%, 等级为中占 1.14%, 等级为次占 0.86%,

等级为差占 0.72%, 预测曲线变化过程与实际检测值吻合度较高, 可较为准确地预测路面状况指数 *IRI* 的发展趋势。




图 4 大数据模型预测 *IRI* 结果与实测值对比

Fig. 4 *IRI* results predicted with big data model v. s. measured values

为了更清楚的展示大数据预测模型的预测评定结果与实测值评定的准确性, 现把实测值评定结果与大数据预测结果做对比。图 4 显示, 实测值评级为优, 大数据预测准确率为 86%, 为良、中、次和差的分别占 87%, 90%, 90% 和 100%, 根据实测值数量求得的加权平均准确率为 86.16%, 即为模型验证准确率。

4 结论

针对传统网络模型进行沥青路面长期性能变化预测的局限性, 本研究开展了沥青路面长期性能预测方法研究, 得到以下结论。

(1) 本研究充分考虑数据的基本特征和时序特征, 构建了 LSTM-BPNN 长期性能预测模型, 提出了基于 LSTM-BPNN 模型的道路长期性能的预测方法。通过与传统方法的对比验证说明, 本研究构建的模型可有效提升预测精度。

(2) 基于本研究建立的预测模型对沥青路面的平整度指数 (*IRI*) 进行预测, 发现本研究构建模型的准确率可达到 86.16%, 再次有效验证了 LSTM-BPNN 在沥青路面使用性能领域的可行性、准确性。

(3) 下一步将对不同的沥青路面性能指标进行

深入探讨, 继续优化模型, 以提高模型在沥青路面性能预测方面的适用性。

参考文献:

References:

- [1] 何志敏, 孙晓磊, 杨婉怡, 等. 北京市六环高速公路沥青路面性能预测模型及精度分析 [J]. 市政技术, 2020, 38 (6): 34-36.
HE Zhi-min, SUN Xiao-lei, YANG Wan-yi, et al. Performance Prediction Model and Accuracy Analysis of Asphalt Pavement of Sixth Ring Freeway in Beijing [J]. Road and Traffic Engineering, 2020, 38 (6): 34-36.
- [2] 张含伟, 苗超杰. 基于遗传神经网络的沥青路面抗滑性能预测及验证 [J]. 公路交通技术, 2022, 38 (4): 12-18.
ZHANG Han-wei, MIAO Chao-jie. Prediction and Engineering Verification of Sliding Resistance of Asphalt Pavement Based on Genetic Neural Network [J]. Technology of Highway and Transport, 2022, 38 (4): 12-18.
- [3] 管子豪. 高速公路沥青路面使用性能预测及预防养护决策研究 [D]. 西安: 长安大学, 2019.
GUAN Zi-hao. Research on Performance Prediction and Prevention and Maintenance Decision of Highway Asphalt

- Pavement [D]. Xi'an: Chang'an University, 2019.
- [4] 纪红燕, 王钢, 俞长青, 等. 基于决策树的沥青路面使用性能评价与预测研究 [J]. 公路, 2016, 61 (4): 5.
- JI Hong-yan, WANG Gang, YU Chang-qing, et al. Study on the Evaluation and Prediction of Asphalt Pavement Performance Based on the Decision Tree [J]. Highway, 2016, 61 (4): 5.
- [5] 蒋玮, 许庆正, 单金焕, 等. 基于熵值赋权灰色马尔可夫法的沥青路面使用性能预测 [J]. 中国科技论文, 2022, 17 (6): 595-601.
- JIANG Wei, XU Qing-zheng, SHAN Jin-huan, et al. Prediction of Asphalt Pavement Performance Based on Entropy Weighted Grey Markov Method [J]. China Sciencepaper, 2022, 17 (6): 595-601.
- [6] 李鑫, 张定邦, 骆顺天, 等. GM (1, 1) 模型在沥青路面平整度预测中的应用 [J]. 湖北理工学院学报, 2017, 33 (1): 41-45.
- LI Xin, ZHANG Ding-bang, LUO Shun-tian, et al. Application of GM (1, 1) Model in Prediction of Asphalt Pavement Smoothness [J]. Journal of Hubei Polytechnic University, 2017, 33 (1): 41-45.
- [7] 杜顺成, 杨妍, 王锐. 山区强降雨环境下沥青路面结构性能预测 [J]. 西安工业大学学报, 2022, 42 (2): 139-146.
- DU Shun-cheng, YANG Yan, WANG Rui. Prediction of Structural Performance of Asphalt Pavement Affected by Heavy Rainfall in Mountainous Areas [J]. Journal of Xi'an Technological University, 2022, 42 (2): 139-146.
- [8] HOSSEINI S A, SMADI O. How Prediction Accuracy Can Affect the Decision-Making Process in Pavement Management System [J]. Infrastructures, 2021, 6 (2): 28.
- [9] BOSURCI C, PELLECRINO O, SOLLAZZO G. Optimizing Artificial Neural Networks for the Evaluation of Asphalt Pavement Structural Performance [J]. The Baltic Journal of Road and Bridge Engineering, 2019, 14 (1): 58-79.
- [10] LI B, WANG K C, ZHANG A, et al. Automatic Classification of Pavement Crack Using Deep Convolutional Neural Network [J]. International Journal of Pavement Engineering, 2020, 21 (4): 457-463.
- [11] 熊盛华. 基于 BP 神经网络的混合预测模型的实例研究 [D]. 兰州: 兰州大学, 2015.
- XIONG Sheng-hua. Case Study on Hybrid Prediction Model Based on BP Neural Network [D]. Lanzhou: Lanzhou University, 2015.
- [12] 董艳芳, 朱辉, 曾召田, 等. 基于遗传算法神经网络的地源热泵夏季低负荷运行性能预测分析 [J]. 科学技术与工程, 2022, 22 (12): 4984-4991.
- DONG Yan-fang, ZHU Hui, ZENG Zhao-tian, et al. Analysis on Low Load Performance Prediction of Ground Source Heat Pumps in Summer Based on Genetic Algorithm and Back Propagation Neural Network [J]. Science Technology and Engineering, 2022, 22 (12): 4984-4991.
- [13] 金昊鹏, 庞建勇, 姚韦靖. 基于人工神经网络的沥青路面龟裂预测研究 [J]. 河南城建学院学报, 2022, 31 (6): 35-41.
- JIN Hao-peng, PANG Jian-yong, YAO Wei-jing. Prediction of Alligator Cracking of Asphalt Pavement Based on Artificial Neural Network [J]. Journal of Henan University of Urban Construction, 2022, 31 (6): 35-41.
- [14] 王立路, 于金良, 成高立. 沥青路面大修时机预测方法研究 [J]. 工程建设, 2022, 54 (6): 73-78.
- WANG Li-lu, YU Jin-liang, CHENG Gao-li. Study on Prediction Method of Overhaul Time of Asphalt Pavement [J]. Engineering Construction, 2022, 54 (6): 73-78.
- [15] 张志斌. 基于深层循环神经网络的高速公路沥青路面健康状况预测模型 [J]. 公路交通技术, 2022, 38 (4): 62-68.
- ZHANG Zhi-bin. Prediction Model of Highway Asphalt Pavement Health Status Based on Deep Recurrent Neural Network [J]. Technology of Highway and Transport, 2022, 38 (4): 62-68.